Date / / Subject

Lec:2 Entropy

N	F_1	F_2	F_3	Class
1	T	T	1	+
2	T	T	2	+
3	T	F	1	−
4	F	F	1	+
5	F	T	1	−
6	F	T	1	−
7	F	F	1	−
8	T	F	1	+
9	F	T	1	−

$+ \rightarrow 4$

$- \rightarrow 5$

$$E = S = -\sum P \log_2(P)$$

$$= -\left[\frac{4}{9}\log_2(4/9) + 5/9 \log_2(5/9)\right]$$

$$= 0.9911$$

$F_1 \rightarrow$ Class

	+	−	Σ
T	3	1	4
F	1	4	5

$F_1 \rightarrow$

$$E(T) = -\left[3/4 \log_2(3/4) + 1/4 \log_2(1/4)\right] = 0.811$$

$$E(F) = -\left[1/5 \log_2(1/5) + 4/5 \log_2(4/5)\right] = 0.722$$

$$\text{Information gain}(f_1) = S - \sum \frac{N_i}{N} E(T_i) \quad T, F$$

$$= 0.9911 - \frac{4}{9} * 0.811 - \frac{5}{9} * 0.722 = 0.2285$$

* هنشتغل على f1 و f2 عشان مقدرش أحسب الـ var ليوم عكس F3 اللى أقدر أحسبها

$F_2 \rightarrow$ Class

$$\text{Information gain}(f_2) = 0.0092$$

* لو هعمل Dim reduction هتتجاهل F_2 لأن معلوماته عن Class قليلة

Date / / Subject

Surprise

الفكره هنا إني متأكد أو P = 1
فبالتالي مش متفاجئ ← S = 0

$$S = \frac{1}{P}$$

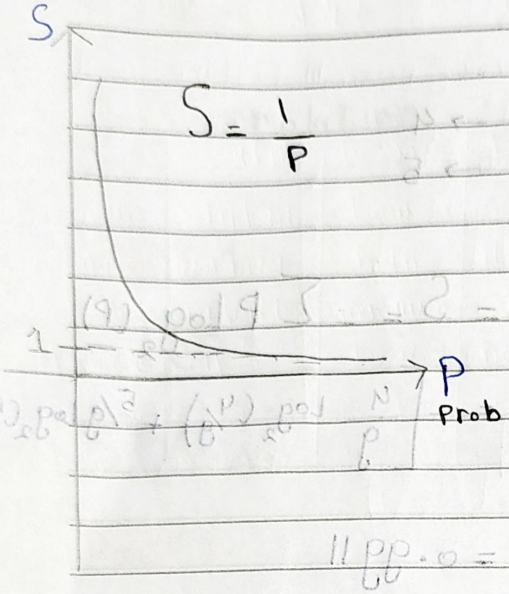

$$S = \log\left(\frac{1}{P}\right)$$

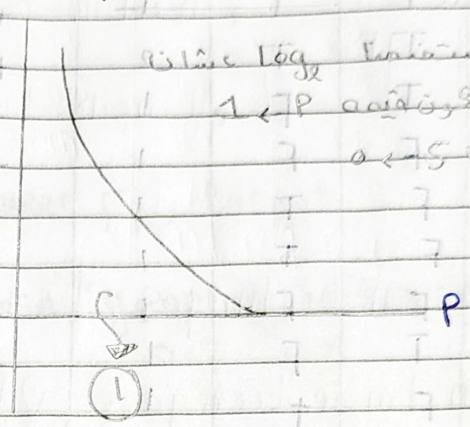

(*) إستخدمنا $\log_2$ عشان
لما تكون قيمه $P < 1$
يكون $S < 0$

$$\sum P.\log_2 \frac{1}{P} = -\sum P.\log_2(P)$$

Gini index

F1	F2	Target
T	T	+
T	T	+
T	F	−
F	F	+
F	T	−
F	T	−
F	F	−
T	F	+
F	T	−

$$\text{Gini index} = 1 - \sum P_i^2$$

at F1

$+ \rightarrow 4$, $- \rightarrow 5$

$$GI = 1 - \left[\left(\frac{4}{9}\right)^2 + \left(\frac{5}{9}\right)^2\right] = 0.493$$

الكلي GI

(*) بعدكده هحسب GI لـ F1 , F2

و الكلي GI ده المعيار الخاص اللي هقيس بيه إذا كان المتغير ده كويس "يكون أقل منه"
أو متغير ردي "يكون أعلى منه"

Date / / Subject

F1

	+	−	
T	3	1	4
F	1	4	5

$$GI_{\mp}^{T} = 1 - \left[\left(\tfrac{3}{4}\right)^2 + \left(\tfrac{1}{4}\right)^2 \right] = 0.375$$

$$GI_{\mp}^{F} = 1 - \left[\left(\tfrac{1}{5}\right)^2 + \left(\tfrac{4}{5}\right)^2 \right] = 0.32$$

$$GI(F_1) = \underbrace{4/9}_{P(T)} * \underbrace{0.375}_{GI(T)} + \underbrace{5/9}_{P(F)} * \underbrace{0.32}_{GI(F)} = 0.3444$$

$$GI(F_2) = 0.4989$$

لو هستخدم هستخدم F_2 لأنه عنده تصليل أكتر من الباقي (GI)

$$GI = 1 - \left[P^2 + (1-P)^2 \right]$$

$GI \Rightarrow P^2$

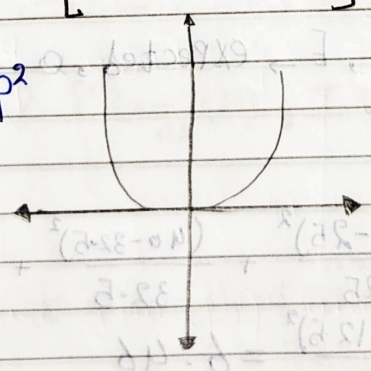

Date / / Subject

Chi_Square test χ^2

F_1 gender	F_2 occupation	F_3 income	T target
male	student	Low	sub
male	working	high	Not
Female	student	medium	sub
Female	self	Low	not

income \ T	Sub	Not sub	
Low	25	35	60
medium	12	18	30
high	50	20	70

Contingency table

income \ T	Sub	Notsub	
Low	20	30	50
medium	40	25	65
high	10	15	25
	70	70	140

observed table

income \ T	Sub	Not Sub
Low	$\frac{50\times70}{140}$	$\frac{50\times70}{140}=25$
medium	$\frac{65\times70}{140}$	$\frac{65\times70}{140}=32.5$
high	$\frac{25\times70}{140}$	$\frac{25\times70}{140}=12.5$

expected table

$$\chi^2=\sum\frac{(O-E)^2}{E}$$, E → expected , O → observed

$$=\frac{(20-25)^2}{25}+\frac{(30-25)^2}{25}+\frac{(40-32.5)^2}{32.5}+\frac{(25-32.5)^2}{32.5}+\frac{(10-12.5)^2}{12.5}+\frac{(15-12.5)^2}{12.5}=6.46$$

Date / / Subject

χ^2

0.05 , df , $df = (r - 1) * (c - 1)$

rows Coulom

Significant

$df = (3-1) * (2-1) = 2$

H_0: There is no importance for f_1

H_a: There is an importance for f_1

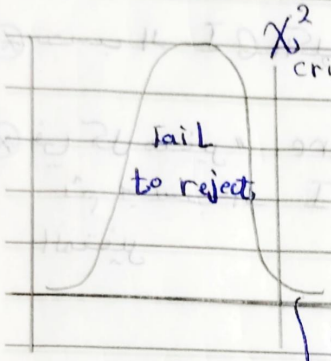

$\chi^2_0 \equiv$ From table

reject H_0

Then we reject H_0

ملخص المحاضرة

1. Entropy ← مقياس لعدم اليقين ,

Information gain يستخدم لحساب

ومن IG نحسب أهم الـ feature يحتوي على معلومات

$$\text{Entropy} = -\sum P \log_2(P) \quad , \quad IG = S - \sum \frac{N_i}{N} . E(\xi)$$

بديلها رمز S

أنواع القيم اللي جوه المتغير

زي T , F

(*) كل ما كان IG أعلى كل ما كان المتغير ده أفضل من غيره

if $gain(f_1) > gain(f_2)$

$\therefore var(f_1) > var(f_2)$

Date / / Subject

2. Gini index → يقيس مدى التشتت (أو) بيقيس التضليل

$$GI = 1 - \sum P_i^2$$

* كل ما كان GI أقل يبقي المتغير به تشتت أقل و يبقى ده أفضل متغير

* بحسب ال GI الكلي و ده هو المعيار اللي مقيم بيه باقي المتغيرات

* في كل متغير " Feature " بقيس ال GI داخل كل حاله في المتغير ده ثم بحسب ال GI للمتغير بإني بجمع حاصل ضرب ال GI للحاله في نسبتها داخل المتغير

Chi Square distribution

- Positive
- Sum of Square Normal
- Not Symmetric
- Shape depends on degree of Freedom
- df = n - 1 or = k → k is number of feature
- Shape is right Skewed

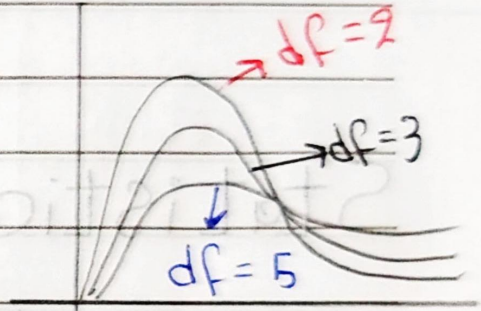

$$U = Z_1^2 + Z_2^2 + Z_3^2$$

$$U \sim \chi^2_{(3)}$$

df = 3